



# Introdução a Inteligência Artificial

## Busca em grafos

Alneu de Andrade Lopes



# Busca

- ↪ Imagine que você está em uma nova cidade e deseja encontrar um bar para beber um chopp
- Se você tem um mapa, você pode descobrir como sair de onde você está para chegar ao bar
  - Se você não tem um mapa, você poderia caminhar sem rumo até encontrar um bar
  - Ou você poderia procurar sistematicamente por um bar



# Busca

- ↪ Você poderia, por exemplo, utilizar o seguinte algoritmo de “encontrar bar”
1. Procure um bar
  2. Caso não encontrou um bar, vá para um local não visitado por você e repita o passo 1
  3. Se você encontrou um bar, vá e beba um chopp
  4. Após o décimo chopp, saia e caia na sarjeta




# Busca

- ↪ Um sistema de IA pode resolver problemas da mesma forma:
  - Ele sabe onde ele está (conjunto de informações inicial)
  - Ele sabe onde deseja ir (estado objetivo)
  - Ele sabe como ir para um próximo estado
- ↪ Resolver problema em IA envolve a busca pelo estado objetivo
- ↪ Simples sistemas de IA reduzem raciocínio a busca



# Busca

- ↪ Problemas de busca são frequentemente descritos utilizando diagramas de árvores
  - Nó inicial = onde a busca começa
  - Nó objetivo = onde ela termina (Fig 1)
- ↪ Objetivo: Encontrar um caminho que ligue o nó inicial a um nó objetivo



**Fig 1**



# Busca

## ↪ Entrada:

- Descrição dos nós inicial e objetivo
- Procedimento que produz os sucessores de um nó arbitrário


## ↪ Saída:


- Sequência legal de nós iniciando com o nó inicial e terminando com o nó objetivo
- Exemplos: encontrar o menor caminho entre S e G no mapa a seguir.



# Exemplo

↪ Dado o mapa (grafo) abaixo, encontrar a menor distância de S a G









# Exemplo: palavras cruzadas





Fig 2



# Uma árvore de busca

↪ Uma busca pode ser definida graficamente:




↪ O objetivo é atravessar a árvore partindo do estado inicial até o estado objetivo



# Tipos de busca


- ↳ Busca em profundidade envolve buscar o final de um caminho antes de tentar um caminho alternativo:





# Tipos de busca (cont)

- ↪ Busca em largura envolve escolher um caminho e segui-lo até o próximo ponto de decisão ou até o objetivo ser atingido:





# Problemas da busca

- ↪ Com o aumento da árvore de decisão e do número de possíveis caminhos, o tempo de busca aumenta
- ↪ Existem várias formas de reduzir o tempo de busca, algumas das quais serão discutidas mais adiante



# Possíveis situações

↪ Mais de um nó objetivo

↪ Mais de um nó inicial

↪ Nestas situações

- Encontrar qualquer caminho de um nó inicial para um nó objetivo
- Encontrar melhor caminho



# Definições importantes

- ↪ Profundidade: número de ligações entre um dado nó e o nó inicial
- ↪ Largura: número de sucessores (filhos) de um nó



# Algoritmo básico de busca

- 1 Definir um conjunto  $L$  de nós iniciais;
- 2 Se  $L$  é vazio  
Então Busca não foi bem sucedida  
Senão Escolher um nó  $n$  de  $L$ ;
- 3 Se  $n$  é um nó objetivo  
Então Retornar caminho do nó inicial até  $n$ ;  
Parar  
Senão Remover  $n$  de  $L$ ;  
Adicionar a  $L$  todos os filhos de  $n$ , rotulando cada um com o seu caminho até o nó inicial;  
Voltar ao passo 2





# Algoritmos de Busca

- ↪ Existem vários algoritmos de busca diferentes, o que os distingue é a maneira como o nó  $n$  é escolhido no passo 2
- ↪ Métodos de busca
  - Busca cega: a escolha depende da posição do nó na árvore de busca
  - Busca heurística: A escolha utiliza informações específicas do domínio para ajudar na decisão



# Busca cega

## ↪ Técnicas de busca cega

- Grande número de métodos
  - ⑩ Busca em Profundidade
  - ⑩ Busca em Largura



# Técnicas de busca cega

## ↪ Busca em Profundidade (BP)

- A árvore é examinada de cima para baixo
- Aconselhável nos casos onde os caminhos improdutivos não são muito longos

## ↪ Busca em Largura (BL)

- A árvore é examinada da esquerda para a direita
- Aconselhável quando o número de ramos não é muito grande

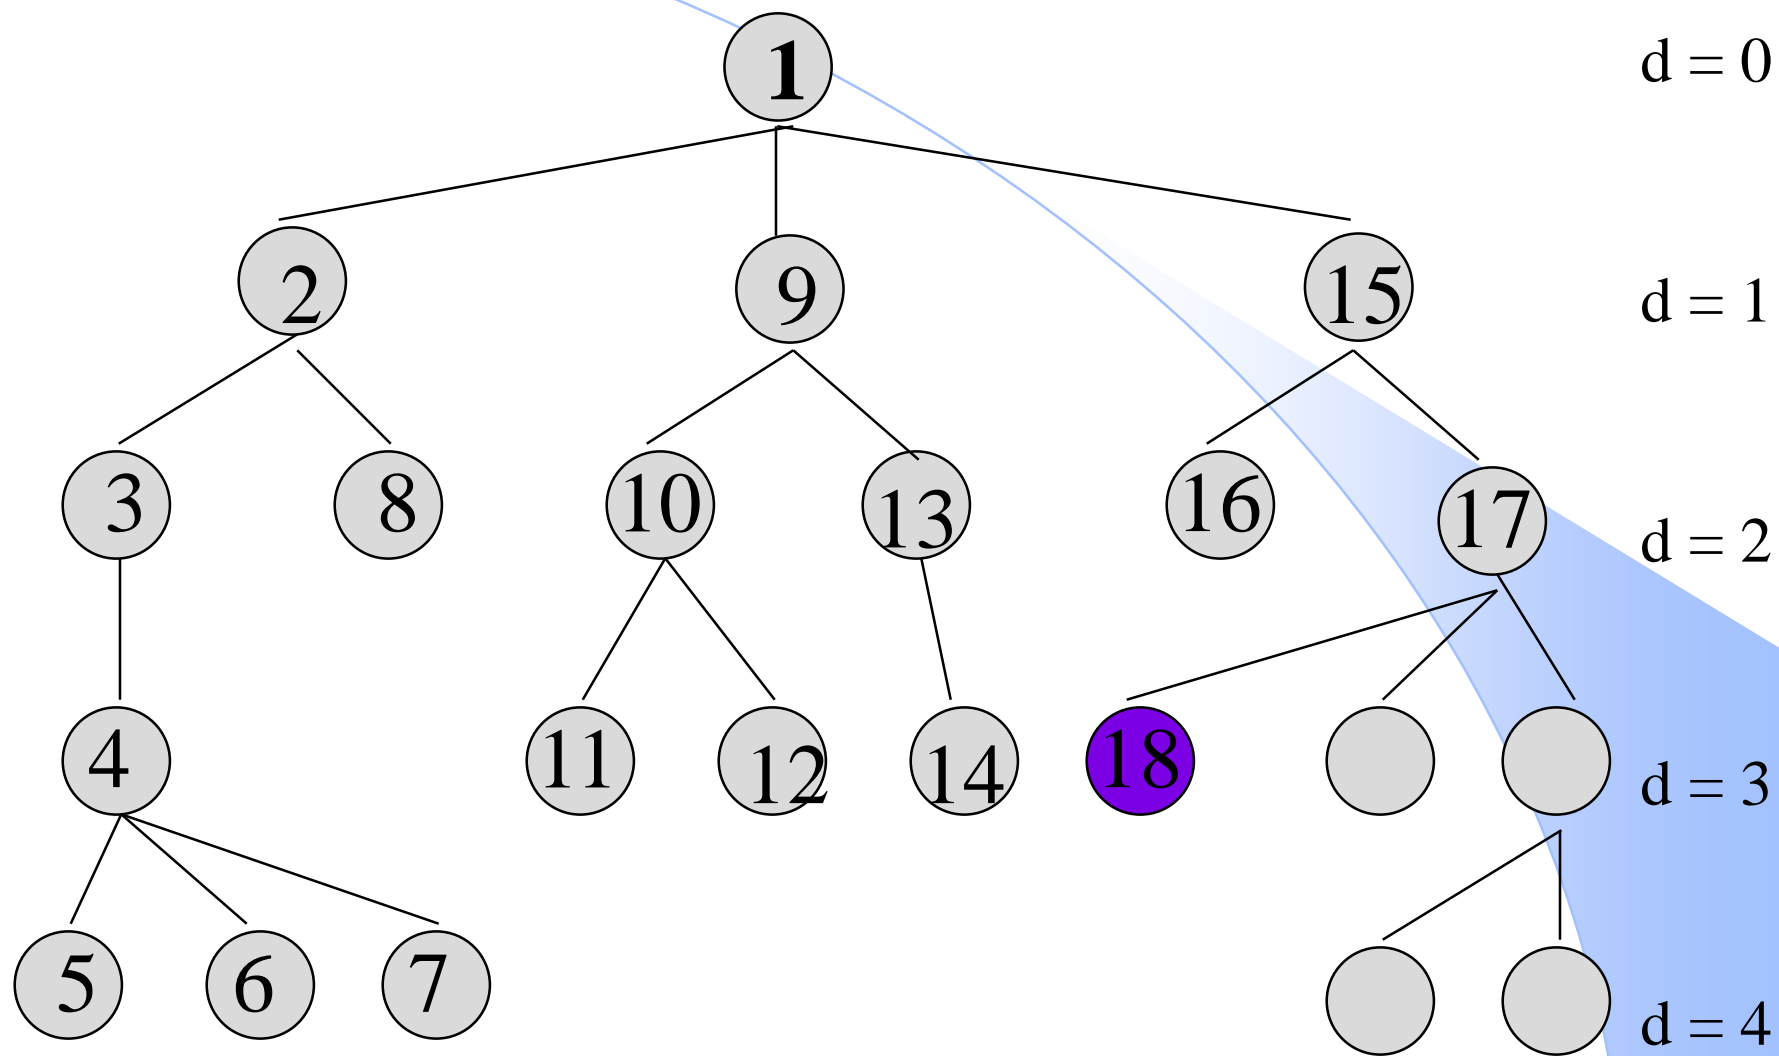


# Algoritmo BP

- 1 Definir um conjunto L de nós iniciais
- 2 Seja n o primeiro nó de L;  
Se L é vazio  
Então Busca não foi bem sucedida
- 3 Se n é um nó objetivo  
Então Retornar caminho do nó inicial até n;  
Parar  
Senão Remover n de L;  
Adicionar ao **início** de L todos os filhos de n, rotulando cada um com o seu caminho até o nó inicial;  
Voltar ao passo 2;



# Busca em profundidade





# BP Em Prolog

```
% implementando o Alg.  
caminho1(O,D,Cam) :-  
    caminho2([[O]],D,Cam).  
caminho2([[D|C]|_],D,[D|C]).  
caminho2([[A|R]|Outros],D,C):-  
    todos_filhos(A,R,L),  
    append(L,Outros,L1),  
    caminho2(L1,D,C).
```

```
todos_filhos(A,R,L):-  
    findall([X,A|R],  
        (aresta(A,X),  
        not(member(X,R))),L).
```

```
append([],L,L).  
append([H|T],L,[H|T1]):-  
    append(T,L,T1).
```



# Implementação 2

% busca usando o backtracking do  
Prolog

caminho(O,D,Cam) :-

    caminho(O,D,[],Cam).

caminho(D,D,C,[D|C]).

caminho(A,D,Ac,C):-

    aresta(A,X),

    not(member(X,Ac)),

    caminho(X,D,[A|Ac],C).




# Algoritmo BL

- 1 Definir um conjunto L de nós iniciais
- 2 Seja n o primeiro nó de L;  
Se L é vazio  
Então Busca não foi bem sucedida
- 3 Se n é um nó objetivo  
Então Retornar caminho do nó inicial até n;  
Parar  
Senão Remover n de L;  
Adicionar ao **final** de L todos os filhos de n, rotulando  
cada um com o seu caminho até o nó inicial;  
Voltar ao passo 2;



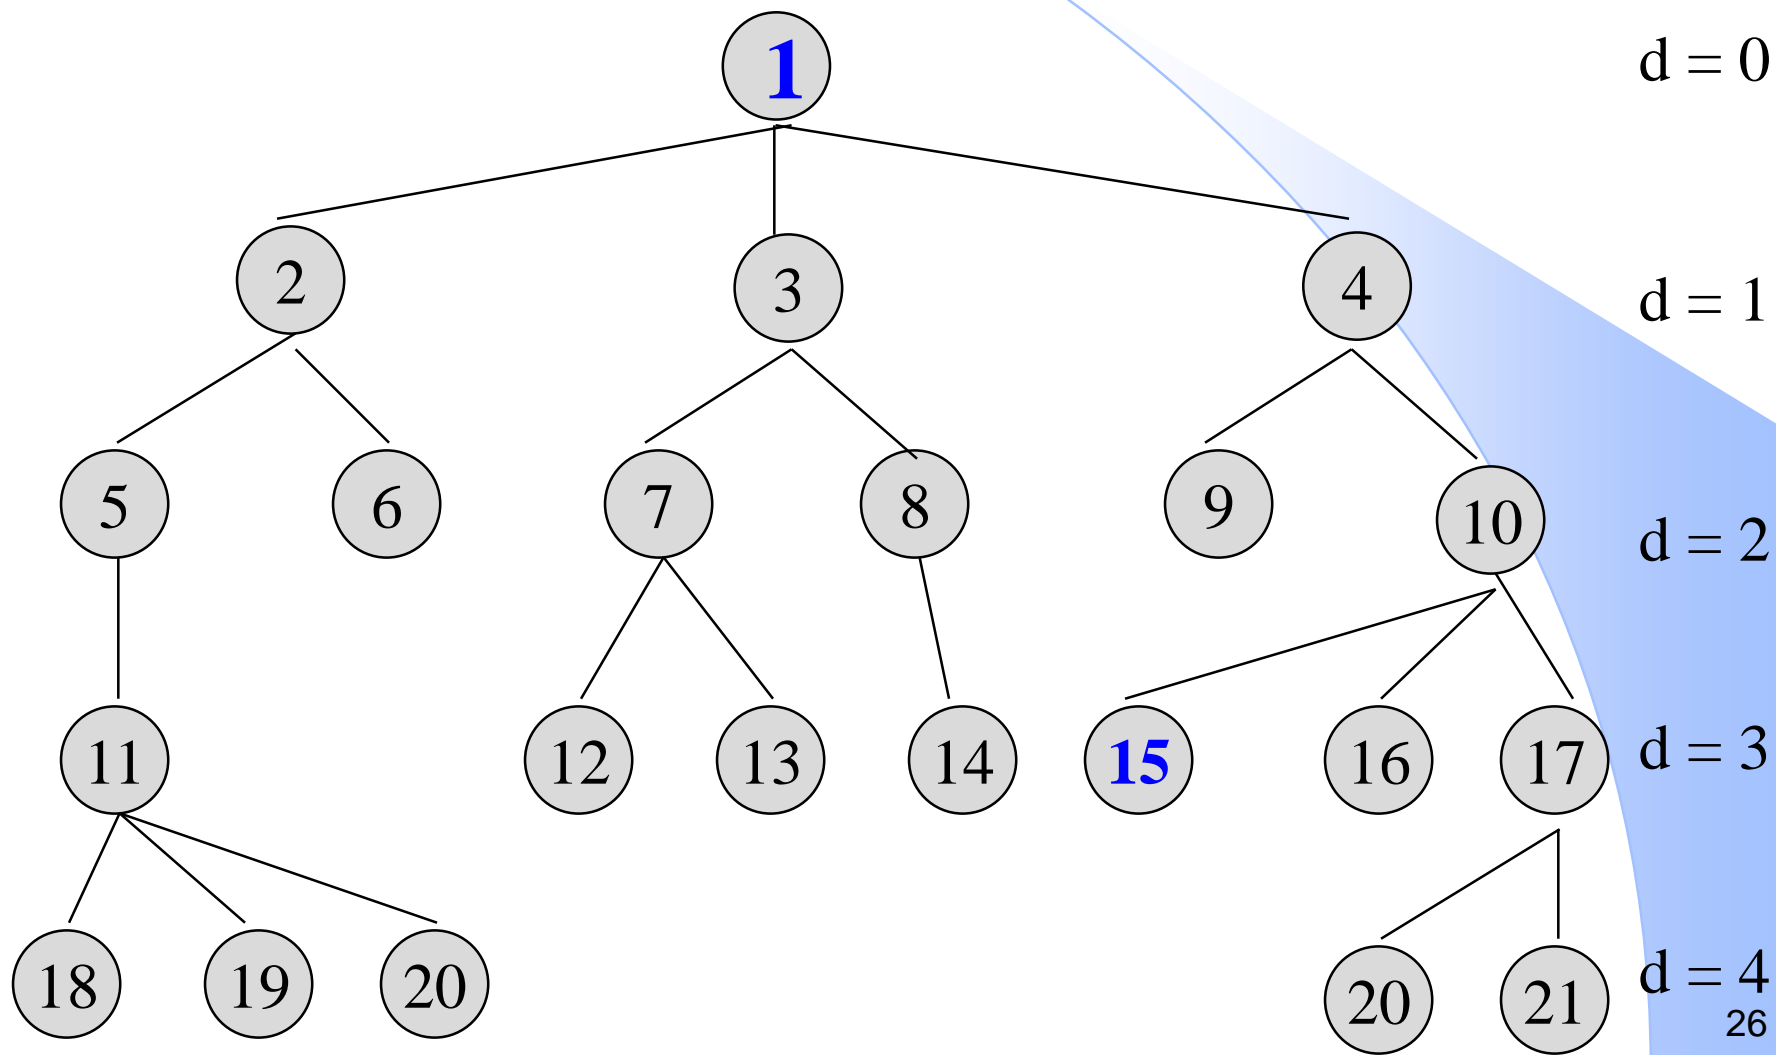


# Busca em largura






**Exemplo 1:** Dada a árvore abaixo, utilizando BP, indique: a) Memória máxima e b) Número mínimo de passos necessários para atingir um dos nós objetivos





# Exercício





# Resposta ao exemplo 1

a)  $1 L = \{1\}$

$$2 L = \{2_1, 3_1, 4_1\}$$

$$3 L = \{5_{21}, 6_{21}, 3_1, 4_1\}$$

$$4 L = \{11_{521}, 6_{21}, 3_1, 4_1\}$$

$$5 L = \{18_{11521}, 19_{11521}, 20_{11521}, 6_{21}, 3_1, 4_1\}$$

$$6 L = \{19_{11521}, 20_{11521}, 6_{21}, 3_1, 4_1\}$$

$$7 L = \{20_{11521}, 6_{21}, 3_1, 4_1\}$$

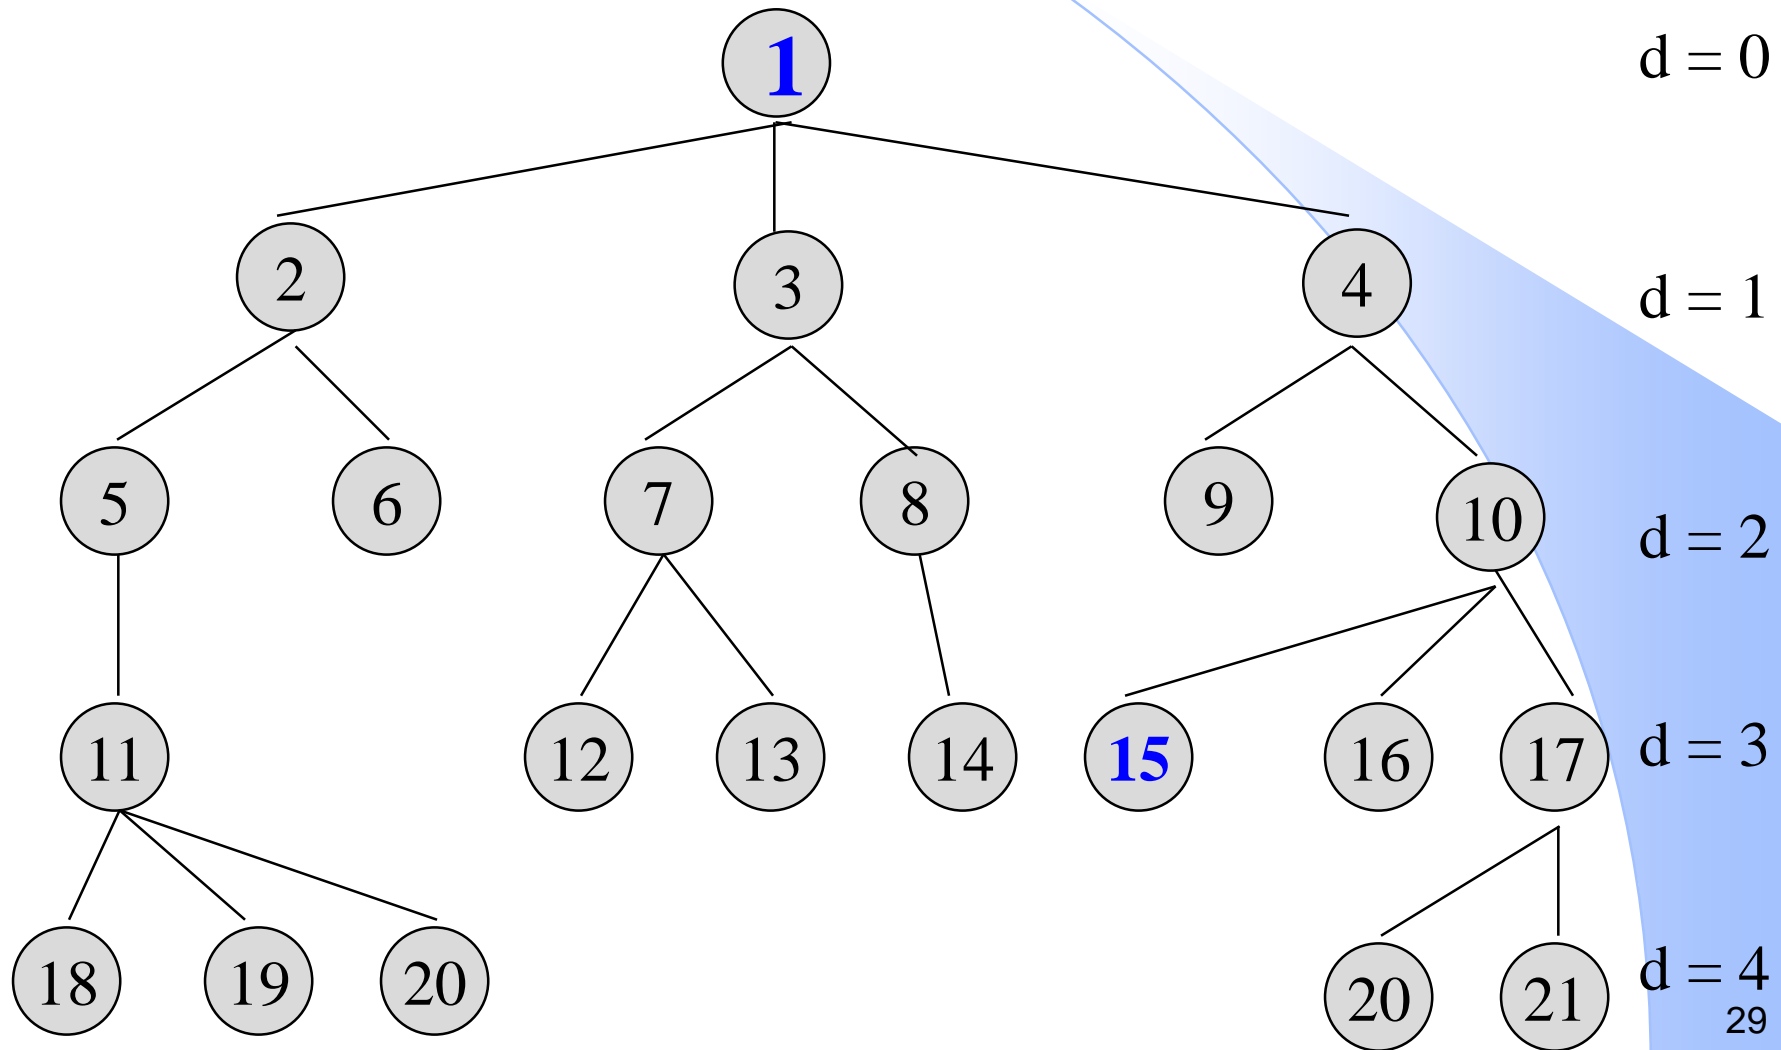
$$8 L = \{6_{21}, 3_1, 4_1\}$$

$$9 L = \{3_1, 4_1\}$$

....

$$18 L = \{15_{1041}, 16_{1041}, 17_{1041}\}$$

➤ **Exemplo 2:** Dada a árvore abaixo, **utilizando BL**, indique: a) Memória máxima e b) Número mínimo de passos necessários para atingir um dos nós objetivos





# Observações

- ↪ BP e BL não precisam ser realizadas em uma ordem específica
- ↪ Memória utilizada pelas duas técnicas
  - BP: precisa armazenar todos os filhos não visitados de cada nó entre nó atual e nó inicial
  - BL: antes de examinar nó a uma profundidade  $d$ , é necessário examinar e armazenar todos os nós a uma profundidade  $d - 1$
  - BP utiliza menos memória



# Observações

## ↪ Quanto ao tempo

- BP é geralmente mais rápida
- Métodos de busca cega não examinam a árvore de forma ótima, o que poderia minimizar o tempo gasto para resolver o problema



# Técnicas exaustivas de busca

- ↪ Completude: a solução sempre será encontrada?
- ↪ “Optimalidade”: o caminho mais curto será encontrado antes dos caminhos mais longos?
- ↪ Eficiência: quais são os requisitos de memória e tempo de execução?





# Busca Baseada em Agenda

- 1 pegue o próximo nó na agenda;
- 2 Se é um nó meta, pare;
- 3 Senão
  - 1 Obtenha seus filhos;
  - 2 Coloque-os na agenda;
  - 3 Vá para o passo 1.

Agenda: lista de nós a serem avaliados  
(backtracking)



# Pesquisa baseada em Agenda (Agenda-based search)

```
% search(Agenda,Goal) <- Goal é um nó meta, e um
%                               nó filho de um dos nós em
%                               Agenda
search(Agenda,Goal):-
    next(Agenda,Goal,Rest),
    goal(Goal).
search(Agenda,Goal):-
    next(Agenda,Atual,Rest),
    children(Atual,Filhos),
    add(Filhos,Rest,NovaAgenda),
    search(NovaAgenda,Goal).
```



# Busca em profundidade x busca em largura (Depth-first vs. breadth-first search)

## ↳ Busca em profundidade (*Depth-first*)

- ⑩ agenda = pilha (last-in first-out)
- ⑩ incompleta: pode ficar preso em um ramo infinito
- ⑩ Nenhuma propriedade de menor caminho
- ⑩ Requisito de memória:  $O(B \times n)$   
n = n.médio de filhos  
B = profundidade

## ↳ Busca em largura (*Breadth-first*)

- ⑩ agenda = fila (first-in first-out)
- ⑩ completa: garante encontrar todas as soluções
- ⑩ Primeira solução encontrada no menor caminho
- ⑩ Requisito de memória:  $O(B^n)$



# Busca informada não exaustiva

- ↪ A busca exaustiva (anteriores) no pior caso examinam todos os nós;
- ↪ Isto porque todos os filhos de um nó são adicionados a agenda.
- ↪ Adicionando só os nós “mais promissores” tem-se um busca não exaustiva (não necessariamente completa).



# Resumo Principais Tópicos

↪ Busca: paradigma de resolução de problemas

↪ Métodos de busca

- Busca cega

- ⑩ Busca em profundidade

- ⑩ Busca em largura

- Busca heurística

- ⑩ Algoritmo A (discutido adiante)


- ⑩ Hill Climbing (Anexo)

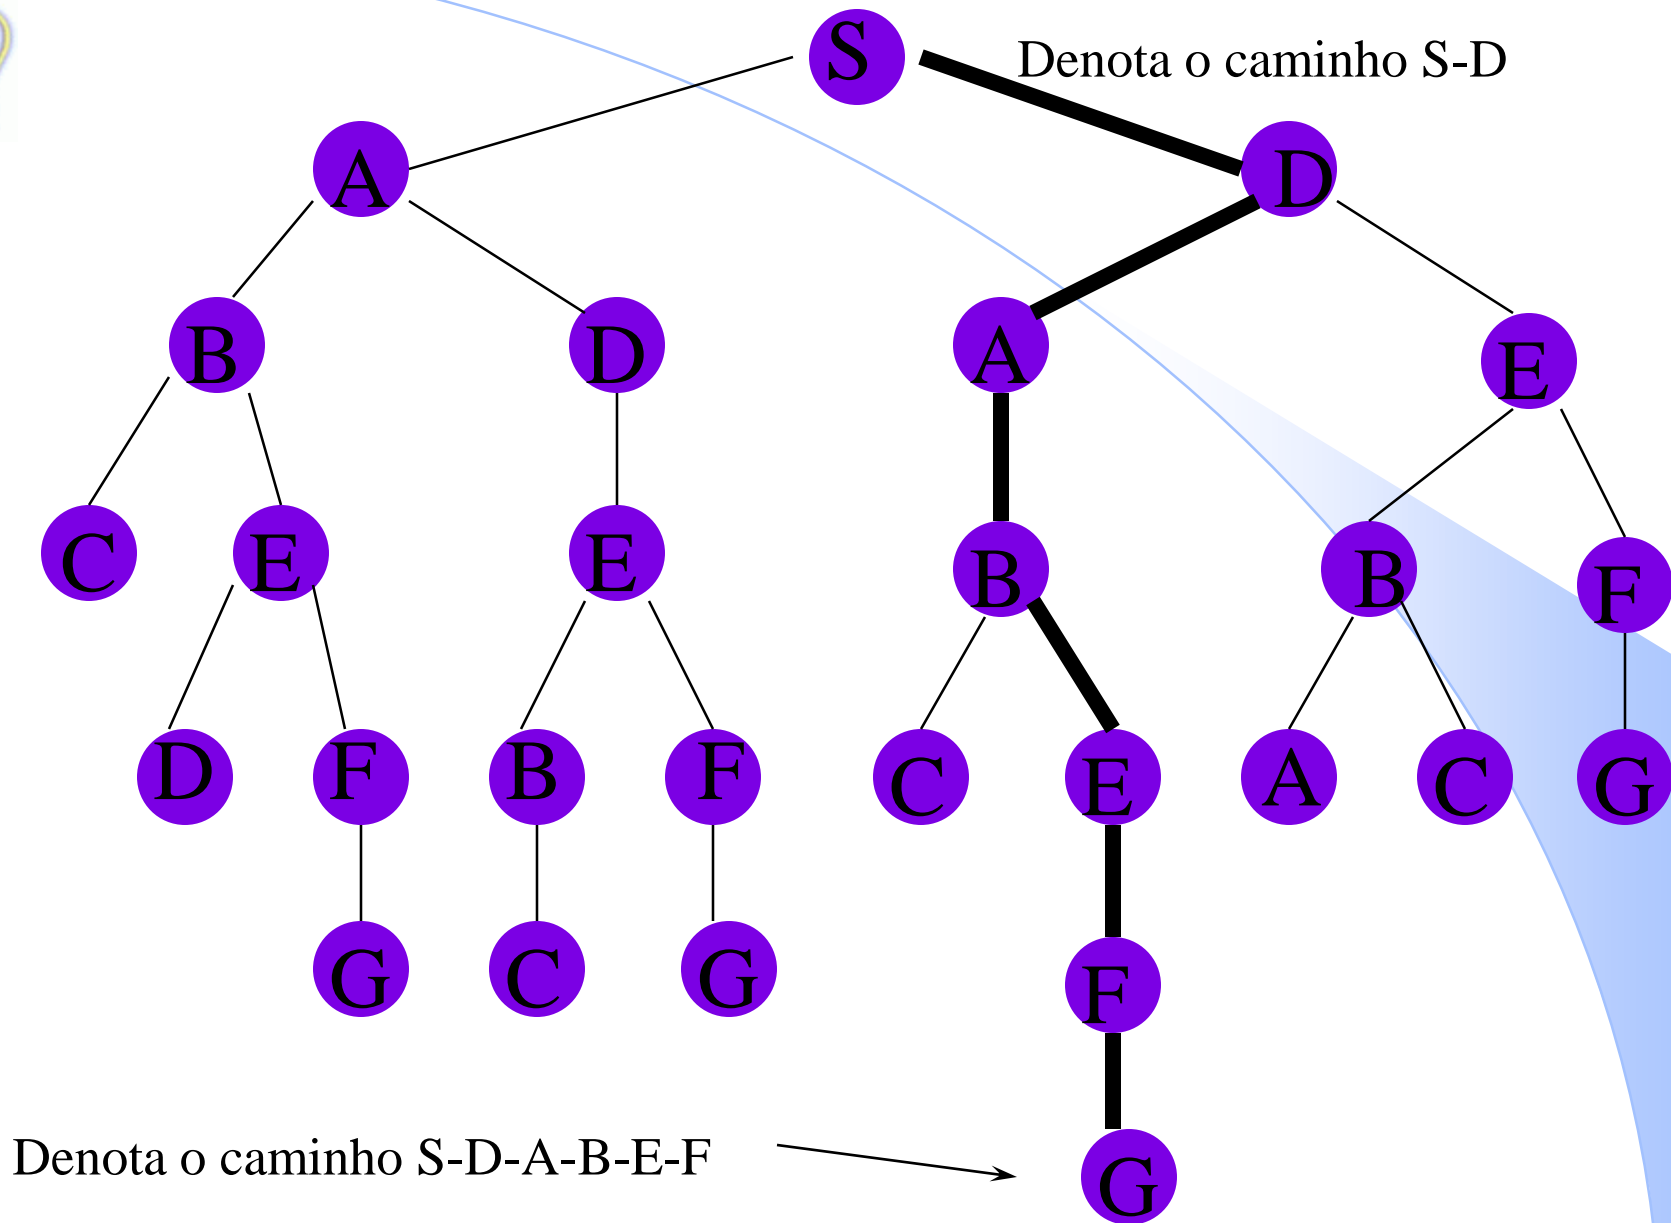
- ⑩ Busca em feixe (Anexo)



# Exemplo

↪ Dado o grafo abaixo, encontrar a menor distância de S a G







# Problemas da busca

- ↪ Com o aumento da árvore de decisão e do número de possíveis caminhos, o tempo de busca aumenta
- ↪ Existem várias formas de reduzir o tempo de busca, alguns dos quais serão discutidos mais adiante





# Busca Heurística

- ↪ Digamos que você está numa Cidade, e quer pegar um trem para casa, mas não sabe qual deve pegar.
- ↪ Se você morasse na zona Norte, naturalmente ignoraria todos os trens que fossem para o sul.
- ↪ Se você morasse na zona Sul, naturalmente ignoraria todos os trens que fossem para o Norte.



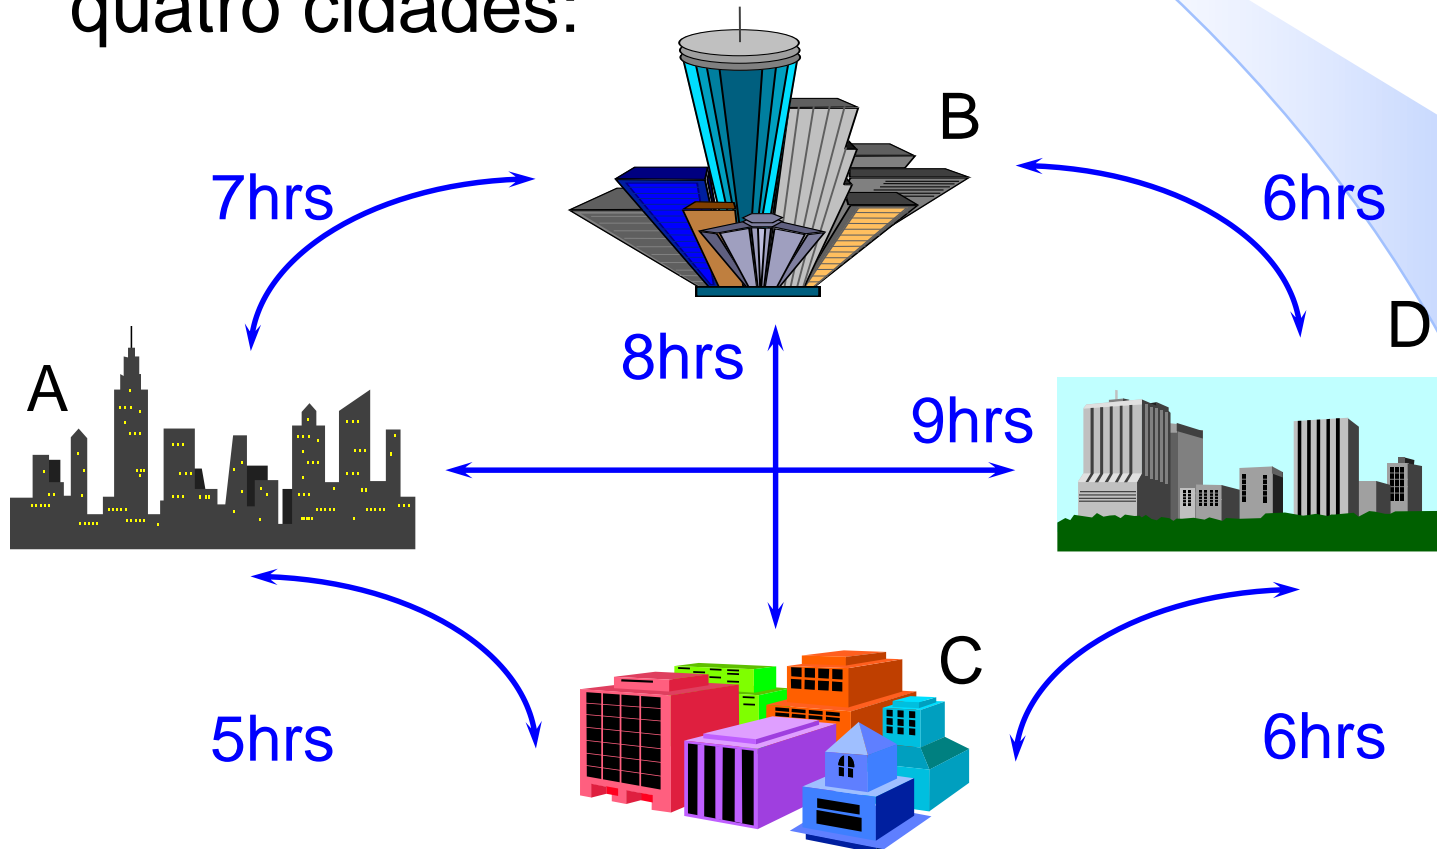
# Exemplo: problema do caixeiro viajante (TSP)

- ↪ Um caixeiro viajante deve visitar  $N$  cidades em sua área de vendas
- ↪ O caixeiro começa de uma base, visita cada cidade uma única vez e retorna à sua cidade no final
- ↪ A cada viagem esta associado um custo
  - O caixeiro deve percorrer a rota mais curta



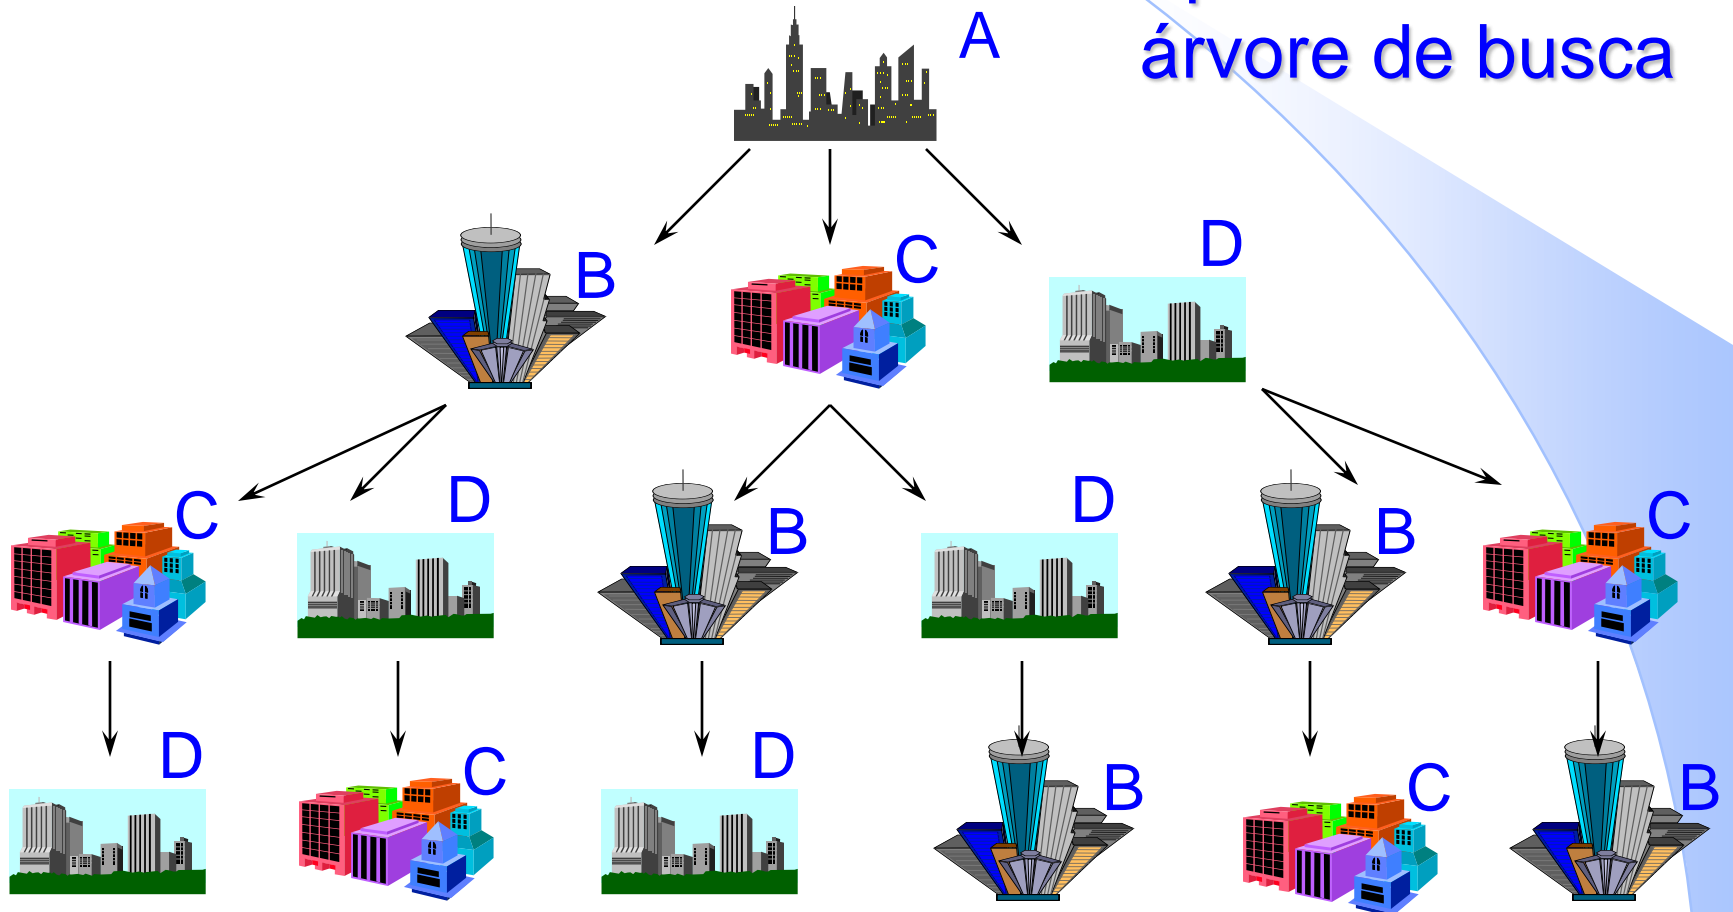
# O problema TSP

Considere as rotas definidas entre estas quatro cidades:





# O problema do TSP representado como árvore de busca





# Explosão Combinatória

- ↪ Com quatro cidades, temos 6 caminhos possíveis.
- ↪ Com dez cidades, temos 362.880 caminhos possíveis.
- ↪ Quanto mais cidades adicionarmos ao TSP, mais caminhos possíveis há.
- ↪ O que nos leva a uma *explosão combinatória*.
- ↪ Como prevenir ou pelo menos limitar isto?



# Problemas Clássicos

- ↪ Encontrar um caminho para um objetivo
- ↪ Missionários e canibais
- ↪ N-rainhas
- ↪ Jogos
- ↪ Xadrez
- ↪ Gamão
- ↪ Torres de Hanói
- ↪ Simplesmente encontrar um objetivo
- ↪ Problema do tabuleiro de xadrez danificado



# Observações

↪ Perguntas a serem feitas antes de utilizar métodos de busca:

- Busca é a melhor maneira para resolver o problema?
- Quais métodos de busca resolvem o problema?
- Qual deles é o mais eficiente para este problema?



# Algoritmo A

↳ Um *algoritmo A* é um algoritmo de busca *best-first* que objetiva minimizar o custo total do caminho do nó início ao nó meta.

$$\blacksquare f(n) = g(n) + h(n)$$

Estimativa do  
custo total ao  
longo do caminho  
através de n

Custo real para  
alcançar n

Estimativa  
para alcançar  
a meta a partir  
de n






# exemplo

➤ Menor caminho:

*start-r-s-goal*

➤ Não é encontrado imediatamente.

- $h(p) < h(r)$
- Depois de q ser investigado r é colocado na agenda, com  
 $f(r) = 1 + 2 = 3$   
 $f(s) = 3 + 1 = 4$





- ↪ O algoritmo  $A$  é completo: desde que  $g(n)$  previne que a busca fique presa em um caminho infinito (comporta-se como na busca *breadth-first*);
- ↪ Aliás, *bf search* é um caso especial do algoritmo  $A$ , com  $h(n)=0$  para todos os nós.



- ↪ É ótimo: sempre leva a solução de menor caminho (se arestas têm os mesmos custos);
- ↪ Um algoritmo  $A$  com um heurística otimista é chamado  $A^*$ .
  - Obs 1  $h(n)$  é uma heurística admissível se nunca superestima o custo para alcançar o objetivo (otimista)
  - Obs 2. Melhor heurística não quer dizer mais otimista. Ao contrário uma boa heurística é tão pessimista quanto possível sem se tornar não admissível.



# Exercícios



# Caminho do cavalo no tabuleiro de xadrez

- ↪ Cavalo numa posição  $(x,y)$  pode ir para
- ↪  $(x+\text{deltax}, y+\text{deltay})$
- ↪  $(\text{deltax}, \text{deltay}) \in \{(2,1), (2,-1), (-2,1), (-2,-1), (1,2), (-1,2), (1,-2), (-1,-2)\}$

```
pode_ir([X,Y],[X1,Y1):-  
    delta(Dx,Dy),  
    X1 is X+Dx, 0<X, X<9,  
    Y1 is Y + Dy, 0<Y, Y<9.
```

```
    delta(2,1).  
    delta(2,-1).  
    ...
```



# Caminho cavalo

```
caminho_cav(I,F,C):-  
    caminho_cav(F,[I],C).
```

```
caminho_cav1(X,[X|L],[X|L]).
```

```
caminho_cav1(I,[E|C],Cam):-  
    pode_ir(E,E1),  
    not(member(E1,C)),  
    caminho_cav1(I,[E1,E|C],Cam).
```



# 8 rainhas



## Ex

/\* transporta de uma margem de um rio para outra margem os objetos milho, galinha, lobo, sendo que não podem ficar juntos m,g e g,l

m1=[m,g,l] b=[] m2=[]

m1=[m,l] b=[g] m2=[] escolhe um da margem1 para transportar para outra

m1=[m,l] b=[] m2=[g]

m1=[m] b=[l] m2=[g]

m1=[m] b=[g] m2=[l] troca o que está na margem2 com o que está no barco

m1=[g] b=[m] m2=[l] troca o que está na margem1 com o que está no barco

...

m1=[] b=[] m2=[g,l,m]

\*/

pode([m,l]).

pode([l,m]).

pode([g]).

pode([m]).

Pode([l]).





```
% plano([[g,l,m],[],[[]],[[],[],[g,l,m]],P)
```

```
plano(O,D,P1) :-
```

```
    plano2([[O]],D,P),
```

```
    inverte(P,P1),
```

```
    show(P1).
```

```
plano2([[D|C]|_],D,[D|C]).
```

```
plano2([[A|R]|Outros],D,C):-
```

```
    todos_filhos(A,R,L),
```

```
    append(Outros,L,L1),
```

```
    plano2(L1,D,C).
```

```
todos_filhos(A,R,L):-
```

```
    findall([X,A|R],
```

```
        (aresta(A,X),not(member(X,R))),
```

```
        L).
```

```
append([],L,L).
```

```
append([H|T],L,[H|T1]):-
```

```
    append(T,L,T1).
```

```
inverte(A,B):-
```

```
    inverte(A,[],B).
```

```
inverte([],B,B).
```

```
inverte([H|T],Ac,B):-
```

```
    inverte(T,[H|Ac],B).
```

```
show([]).
```

```
show([A|R]):-
```

```
    writeln(A),
```

```
    show(R).
```



```
% aresta([[g,l,m],[],[]],[[g,m],[l],[]])
```

```
aresta([L,[],[]],[L2,[X],[]):-
```

```
    member(X,L),
```

```
    retira(X,L,L2),
```

```
    pode(L2).
```

```
aresta([[],[],L],[[],[X],L2):-
```

```
    member(X,L),
```

```
    retira(X,L,L2),
```

```
    pode(L2).
```

```
aresta([L,[],[Y]],[L2,[X],[Y]]:-
```

```
    member(X,L),
```

```
    retira(X,L,L2).
```

```
aresta([L,[],[Y]],[L,[Y],[]).
```

```
aresta([[Y],[],L],[[Y],[X],L2):-
```

```
    member(X,L),
```

```
    retira(X,L,L2).
```

```
aresta([[Y],[],L],[[],[Y],L]).
```

```
aresta([[A],[B],[C]],[[A,B],[],[C]]):-  
    pode([A,B]).
```

```
aresta([[A],[B],[C]],[[B],[A],[C]]).
```

```
aresta([[A],[B],[C]],[[A],[],[B,C]]):-  
    pode([B,C]).
```

```
aresta([[A],[B],[C]],[[A],[C],[B]]).
```

```
aresta([[],[Y],L],[[Y],[],L]).
```

```
aresta([L,[Y],[],[L],[],[Y]]).
```

```
aresta([[],[A],[B,C]],[[],[],[A,B,C]]).
```

```
aresta([[A,B],[C],[],[[A,B,C],[],[]]).
```

```
retira(X,[],[]).
```

```
retira(X,[X|R],R).
```

```
retira(X,[Y|R],[Y|R1]) :-
```

```
    X \= Y,
```

```
    retira(X,R,R1).
```



/\* deseja-se encontrar uma instanciação correta para as cores de cada país de tal forma que países com fronteira não tenham a mesma cor.

predicado

```
colours(country_colour_list) % [(brasil,yellow),(bolivia,red), (uruguai,blue),...]
```

\*/

% representação de vizinhança

```
ngb(brasil,[paraguai,bolivia,uruguai,argentina]).
```

```
ngb(paraguai,[bolivia,brasil,chile]).
```

```
ngb(bolivia,[paraguai,brasil,peru,chile]).
```

```
ngb(argentina,[uruguai,brasil,chile]).
```

```
ngb(chile,[argentina,[paraguai,bolivia]).
```

```
ngb(peru,[bolivia,brasil]).
```



colours([]).

colours([(Country,Colour)|Rest]):-

colours(Rest),

member(Colour,[yellow,blue,red,green]),

not(samecolorNeighbour(Country,Country1,Colour,Rest)).

samecolorNeighbour(Country,Country1,Colour,Rest) :-

member((Country1,Colour),Rest),


neighbour(Country,Country1).

neighbour(Country,Country1):-

ngb(Country,Neighbours),

member(Country1,Neighbours).

go :-



```
colours([(brasil,A),(argentina,B),(uruguai,C),(chile,D)]),  
write('brasil '),write(A),  
write('; argentina '),write(B),  
write('; uruguai '),write(C),  
write('; chile '),write(D),nl,  
fail.
```

go.

gol :- %último na lista o com maior n. de vizinhos

```
colours([(uruguai,C),(chile,D),(argentina,B),(brasil,A)]),  
write('brasil '),write(A),  
write('; argentina '),write(B),  
write('; uruguai '),write(C),  
write('; chile '),write(D),nl,  
fail.
```

gol.



# Referências

- ↪ Capítulo 4 (Russel & Norvig)
- ↪ Capítulo 5 e 6 (Peter Flach)



# Referências para Busca

- ↪ Ginsberg, M. *Essentials of Artificial Intelligence* Parte II, cap 3, 4 e 5
- ↪ Russel & Norvig *Artificial Intelligence A Modern Approach* Parte II, cap 3 e 4
- ↪ Winston



# Anexo

## técnicas adicionais típicas em Aprendizado de máquina

adptadas de  
Simply Logical – Peter Flach





# Detecção de loop

```
% busca depth-first com detecção de loop
search_df_loop([Goal|Rest], Visited, Goal) :-
    goal(Goal) .
search_df_loop([Current|Rest], Visited, Goal) :-
    children(Current, Children) ,
    add_df(Children, Rest, Visited, NewAgenda) ,
    search_df_loop(NewAgenda, [Current|Visited], Goal) .

add_df([], Agenda, Visited, Agenda) .
add_df([Child|Rest], OldAgenda, Visited, [Child|NewAgenda]) :-
    not element(Child, OldAgenda) ,
    not element(Child, Visited) ,
    add_df(Rest, OldAgenda, Visited, NewAgenda) .
add_df([Child|Rest], OldAgenda, Visited, NewAgenda) :-
    element(Child, OldAgenda) ,
    add_df(Rest, OldAgenda, Visited, NewAgenda) .
add_df([Child|Rest], OldAgenda, Visited, NewAgenda) :-
    element(Child, Visited) ,
    add_df(Rest, OldAgenda, Visited, NewAgenda) .
```



# Busca com Backtracking

**% busca depth-first usando backtracking**

```
search_bt(Goal,Goal):-  
    goal(Goal).  
search_bt(Current,Goal):-  
    arc(Current,Child),  
    search_bt(Child,Goal).
```

**% Busca depth-first usando backtracking com  
limite de profundidade**

```
search_d(D,Goal,Goal):-  
    goal(Goal).  
search_d(D,Current,Goal):-  
    D>0, D1 is D-1,  
    arc(Current,Child),  
    search_d(D1,Child,Goal).
```



# *Iterative deepening*

```

search_id(First,Goal):-
    search_id(1,First,Goal).      % start with depth
    1

search_id(D,Current,Goal):-
    search_d(D,Current,Goal).
search_id(D,Current,Goal):-
    D1 is D+1,                    % increase depth
    search_id(D1,Current,Goal).
  
```

- ↳ Combina as vantagens da busca em largura (completa, menor caminho) com as da busca em profundidade (eficiência de memória)



# Busca Best-first (informada)

```
search_bstf([Goal|Rest],Goal):-
    goal(Goal).
search_bstf([Current|Rest],Goal):-
    children(Current,Children),
    add_bstf(Children,Rest,NewAgenda),
    search_bstf(NewAgenda,Goal).
```

```
% add_bstf(A,B,C) <- C contains the elements of
    A and B
%                               (B and C sorted according
    to eval/2)
add_bstf([],Agenda,Agenda).
add_bstf([Child|Children],OldAgenda,NewAgenda):
    -
    add_one(Child,OldAgenda,TmpAgenda),
    add_bstf(Children,TmpAgenda,NewAgenda).

% add_one(S,A,B) <- B is A with S inserted acc.
    to eval/2
add_one(Child,OldAgenda,NewAgenda):-
    eval(Child,Value),
```



```

search_beam(Agenda, Goal) :-
    search_beam(1, Agenda, [], Goal) .

search_beam(D, [], NextLayer, Goal) :-
    D1 is D+1,
    search_beam(D1, NextLayer, [], Goal) .
search_beam(D, [Goal|Rest], NextLayer, Goal) :-
    goal(Goal) .
search_beam(D, [Current|Rest], NextLayer, Goal) :-
    children(Current, Children) ,
    add_beam(D, Children, NextLayer, NewNextLayer) ,
    search_beam(D, Rest, NewNextLayer, Goal) .

```

- ✚ Aqui, o número de filhos adicionados ao “feixe” é dependente da profundidade **D** do nó.
- ✚ Para manter a profundidade como uma variável “global”, a busca é camada por camada.

# Beam search



# Hill-climbing

```
search_hc(Goal,Goal):-  
    goal(Goal).
```

```
search_hc(Current,Goal):-  
    children(Current,Children),  
    select_best(Children,Best),  
    search_hc(Best,Goal).
```

```
% hill_climbing as a variant of best-first search  
search_hc([Goal|_],Goal):-  
    goal(Goal).  
search_hc([Current|_],Goal):-  
    children(Current,Children),  
    add_bstf(Children,[],NewAgenda),  
    search_hc(NewAgenda,Goal).
```



- ↪ Limita o tamanho da Agenda em 1.
- ↪ Chamada greedy search ou busca gulosa, uma vez que não usa backtracking, ( $f(n)=h(n)$ ).
- ↪ Pode atingir um máximo local, e não alcançar o máximo global.



# Simulated annealing

↪ tenta evitar ficar preso em um máximo local

