



# Introdução à Inteligência Artificial

---

Busca em grafos

Prof. Dr. Alneu de Andrade Lopes

LABIC - ICMC - USP São Carlos



# Conteúdo

---

- Parte I
  - Busca exaustiva
- Parte II
  - Busca informada



# Problema de busca

---

- Definido por meio de
  - Um espaço de busca, o qual é um grafo com um ou mais vértices iniciais e um ou mais vértices metas.
  - A solução é um caminho, começando em um vértice inicial e terminando em um vértice meta.
  - Função de custo (um número  $p$ / cada aresta)



# Técnicas exaustivas de busca

---

- Completude: a solução sempre será encontrada?
- “Optimalidade”: o caminho mais curto será encontrado antes dos caminhos mais longos?
- Eficiência: quais são os requisitos de memória e tempo de execução?



# Busca Baseada em Agenda

---

- 1 pegue o próximo nó na agenda;
- 2 Se é um nó meta, pare;
- 3 Senão
  - 1 Obtenha seus filhos;
  - 2 Coloque-os na agenda;
  - 3 Vá para o passo 1.

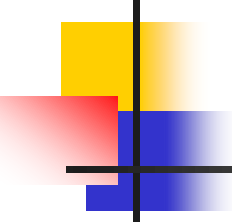
Agenda: lista de nós a serem avaliados  
(backtracking)



# Agenda-based search

---

```
% search(Agenda,Goal) <- Goal é um nó meta, e um
%                               nó filho de um dos nós em
%                               Agenda
search(Agenda,Goal):-
    next(Agenda,Goal,Rest),
    goal(Goal).
search(Agenda,Goal):-
    next(Agenda,Current,Rest),
    children(Current,Children),
    add(Children,Rest,NewAgenda),
    search(NewAgenda,Goal).
```



# Depth-first vs. breadth-first search

---

```
search_df([Goal|Rest],Goal):-
    goal(Goal).
search_df([Current|Rest],Goal):-
    children(Current,Children),
    append(Children,Rest,NewAgenda),
    search_df(NewAgenda,Goal).

search_bf([Goal|Rest],Goal):-
    goal(Goal).
search_bf([Current|Rest],Goal):-
    children(Current,Children),
    append(Rest,Children,NewAgenda),
    search_bf(NewAgenda,Goal).

children(Node,Children):-
    findall(C,arc(Node,C),Children).
```

# Depth-first vs. breadth-first search

## ■ Busca *Breadth-first*

- agenda = fila (first-in first-out)
- completa: garante encontrar todas as soluções
- Primeira solução encontrada no menor caminho
- Requisito de memória:  $O(B^n)$

## ■ Busca *Depth-first*

- agenda = pilha (last-in first-out)
- incompleta: pode ficar preso em um ramo infinito
- Nenhuma propriedade de menor caminho
- Requisito de memória:  $O(B \times n)$   
n = n.médio de filhos  
B = profundidade





# Detecção de loop

```
% depth-first search with loop detection
search_df_loop([Goal|Rest], Visited, Goal) :-
    goal(Goal) .
search_df_loop([Current|Rest], Visited, Goal) :-
    children(Current, Children) ,
    add_df(Children, Rest, Visited, NewAgenda) ,
    search_df_loop(NewAgenda, [Current|Visited], Goal) .

add_df([], Agenda, Visited, Agenda) .
add_df([Child|Rest], OldAgenda, Visited, [Child|NewAgenda]) :-
    not element(Child, OldAgenda) ,
    not element(Child, Visited) ,
    add_df(Rest, OldAgenda, Visited, NewAgenda) .
add_df([Child|Rest], OldAgenda, Visited, NewAgenda) :-
    element(Child, OldAgenda) ,
    add_df(Rest, OldAgenda, Visited, NewAgenda) .
add_df([Child|Rest], OldAgenda, Visited, NewAgenda) :-
    element(Child, Visited) ,
    add_df(Rest, OldAgenda, Visited, NewAgenda) .
```



# Busca Best-first (informada)

---

```

search_bstf([Goal|Rest],Goal):-
    goal(Goal).
search_bstf([Current|Rest],Goal):-
    children(Current,Children),
    add_bstf(Children,Rest,NewAgenda),
    search_bstf(NewAgenda,Goal).

% add_bstf(A,B,C) <- C contains the elements of A and B
%                               (B and C sorted according to eval/2)
add_bstf([],Agenda,Agenda).
add_bstf([Child|Children],OldAgenda,NewAgenda):-
    add_one(Child,OldAgenda,TmpAgenda),
    add_bstf(Children,TmpAgenda,NewAgenda).

% add_one(S,A,B) <- B is A with S inserted acc. to eval/2
add_one(Child,OldAgenda,NewAgenda):-
    eval(Child,Value),
    add_one(Value,Child,OldAgenda,NewAgenda).  implementar

```



# A algorithm

---

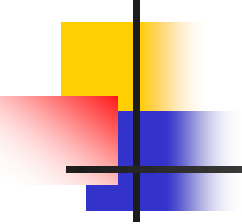
- Um ***algoritmo A*** é um algoritmo de busca best-first que objetiva minimizar o custo total do caminho do no início ao no meta.

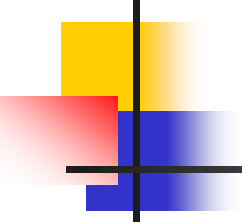
- $f(n) = g(n) + h(n)$

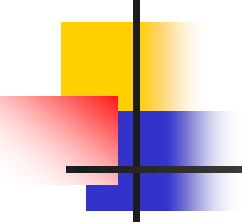
Estimativa do  
custo total ao  
longo do caminho  
através de n

Custo real para  
alcançar n

Estimativa  
para alcançar  
a meta a partir  
de n


- 
- 
- O algoritmo A é completo: desde que  $g(n)$  previne que a busca fique presa em um caminho infinito (comporta-se como na busca breadth-first);
  - Aliás, bf search é um caso especial do algoritmo A, com  $h(n)=0$  para todos os nós.

- 
- 
- É ótimo: sempre leva a solução de menor caminho (se arcos têm os mesmos custos);
  - Um algoritmo A com um heurística otimista é chamado  $A^*$ .
    - Otimista: imagina que o custo de solução é menor do que ele é
    - Obs. Melhor heurística não quer dizer mais otimista. Ao contrário uma boa heurística é tão pessimista quanto possível sem se tornar não admissível.
    - Heurística admissível  $h(n)$  nunca superestime o custo para alcançar o objetivo. Ex: distância em linha reta

- 
- 
- Em geral,
    - Se  $h_1(n) \geq h_2(n)$  para qualquer nó  $n$ , então a heurística  $h_1$  é pelo menos tão *informada* quanto  $h_2$ . ( $h_1$  é mais restritiva: espaço de busca menor)

# exemplo

- Menor caminho:  
**start-r-s-goal**
- Não é encontrado imediatamente.
  - Custo aresta = 1
  - $h(p) < h(r)$
  - Depois de q ser investigado r é colocado na agenda, com  $f(r)=1+2=3$   
 $f(p)=1+1$   
 $f(s)=3+1=4$



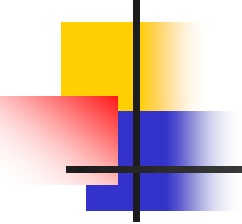


# Busca informada não exaustiva

---

- A busca exaustiva (anteriores) no pior caso examinam todos os nós;
- Isto por porque todos os filhos de um nó são adicionados a agenda.
- Adicionando só os nós “mais promissores” tem-se um busca não exaustiva (não necessariamente completa).





```
search_beam(Agenda, Goal) :-  
    search_beam(1, Agenda, [], Goal) .  
  
search_beam(D, [], NextLayer, Goal) :-  
    D1 is D+1,  
    search_beam(D1, NextLayer, [], Goal) .  
search_beam(D, [Goal|Rest], NextLayer, Goal) :-  
    goal(Goal) .  
search_beam(D, [Current|Rest], NextLayer, Goal) :-  
    children(Current, Children) ,  
    add_beam(D, Children, NextLayer, NewNextLayer) ,  
    search_beam(D, Rest, NewNextLayer, Goal) .
```

- Here, the number of children to be added to the beam is made dependent on the depth **D** of the node
  - in order to keep depth as a 'global' variable, search is layer-by-layer

# Beam search



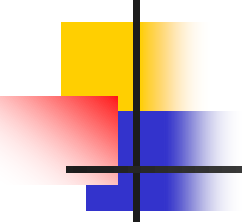
# Hill-climbing

---

```
search_hc(Goal,Goal):-  
    goal(Goal).
```


```
search_hc(Current,Goal):-  
    children(Current,Children),  
    select_best(Children,Best),  
    search_hc(Best,Goal).
```

```
% hill_climbing as a variant of best-first search  
search_hc([Goal|_],Goal):-  
    goal(Goal).  
search_hc([Current|_],Goal):-  
    children(Current,Children),  
    add_bstf(Children,[],NewAgenda),  
    search_hc(NewAgenda,Goal).
```

- 
- 
- Limita o tamanho da Agenda em 1.
  - Chamada greedy search ou busca gulosa, uma vez que não usa backtracking, ( $f(n)=h(n)$ ).
  - Pode atingir um máximo local, e não alcançar o máximo global.

# Simulated annealing

- tenta evitar ficar preso em um máximo local





# Referências

---

- Capítulo 4 (Russel & Norvig)
- Capítulo 5 e 6 (Peter Flach)



# Complemento



# Busca com Backtracking

---

```
% depth-first search by means of backtracking
search_bt(Goal,Goal):-
    goal(Goal) .
search_bt(Current,Goal):-
    arc(Current,Child) ,
    search_bt(Child,Goal) .

% backtracking depth-first search with depth
bound
search_d(D,Goal,Goal):-
    goal(Goal) .
search_d(D,Current,Goal):-
    D>0, D1 is D-1,
    arc(Current,Child) ,
    search_d(D1,Child,Goal) .
```



# *Iterative deepening*

---

```
search_id(First,Goal):-  
    search_id(1,First,Goal).      % start with depth  
    1  
  
search_id(D,Current,Goal):-  
    search_d(D,Current,Goal).  
search_id(D,Current,Goal):-  
    D1 is D+1,                    % increase depth  
    search_id(D1,Current,Goal).
```

- Combina as vantagens da busca em largura (completa, menor caminho) com as da busca em profundidade (eficiência de memória)





# Agenda-based SLD-prover

---

```
prove_df_a(Goal):-
    prove_df_a([Goal]).
```

```
prove_df_a([true|Agenda]).
prove_df_a([(A,B)|Agenda]):-!,
    findall(D,(clause(A,C),conj_append(C,B,D)),Children),
    append(Children,Agenda,NewAgenda),
    prove_df_a(NewAgenda).
prove_df_a([A|Agenda]):-
    findall(B,(clause(A,B),Children),
    append(Children,Agenda,NewAgenda),
    prove_df_a(NewAgenda).
```

```
prove(true):-!.
prove((A,B)):-!,
    clause(A,C),
    conj_append(C,B,D),
    prove(D).
prove(A):-
    clause(A,B),
    prove(B).
```

# Refutation prover for clausal logic

```

refute((false:-true)).
refute((A,C)):-
    cl(Cl),
    resolve(A,Cl,R),
    refute(R).

% refute_bf(Clause) <- Clause is
%                       refuted by clauses
%                       defined by cl/1
%                       (breadth-first search strategy)
refute_bf_a(Clause):-
    refute_bf_a([a(Clause,Clause)],Clause).

refute_bf_a([a((false:-true),Clause)|Rest],Clause).
refute_bf_a([a(A,C)|Rest],Clause):-
    findall(a(R,C),(cl(Cl),resolve(A,Cl,R)),Children),
    append(Rest,Children,NewAgenda),           % breadth-first
    refute_bf_a(NewAgenda,Clause).

```



# Forward chaining

---

```
% model(M) <- M is a model of the clauses defined by
cl/1
model(M) :-
    model([],M) .


model(M0,M) :-
    is_violated(Head,M0),!,           % instance of violated
    clause
    disj_element(L,Head),             % L: ground literal from head
    model([L|M0],M) .                 % add L to the model
model(M,M) .                           % no more violated clauses

is_violated(H,M) :-
    cl((H:-B)),
    satisfied_body(B,M),               % grounds the variables
    not satisfied_head(H,M) .
```

```

married(X);bachelor(X):-man(X),adult(X).
has_wife(X):-married(X),man(X).
man(paul).
adult(paul).

```



# Forward chaining: example

# Forward chaining with depth-bound

```
% model_d(D,M) <- M is a submodel of the clauses
%                      defined by cl/1
model_d(D,M) :-
    model_d(D, [], M) .

model_d(0, M, M) .
model_d(D, M0, M) :-
    D > 0, D1 is D-1,
    findall(H, is_violated(H, M0), Heads) ,
    satisfy_clauses(Heads, M0, M1) ,
    model_d(D1, M1, M) .

satisfy_clauses([], M, M) .
satisfy_clauses([H|Hs], M0, M) :-
    disj_element(L, H) ,
    satisfy_clauses(Hs, [L|M0], M) .
```

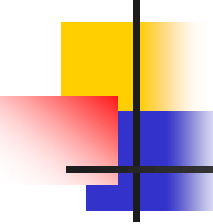


# Solving a puzzle

---

```
% tiles_a(A,M,V0,V) <- goal position can be reached from
%                      one of the positions on A with last
%                      move M (best-first strategy)
tiles_a([v(V,LastMove)|Rest],LastMove,Visited,Visited):-
    goal(LastMove) .
tiles_a([v(V,LastMove)|Rest],Goal,Visited0,Visited):-
    show_move(LastMove,V) ,
    setof0(v(Value,NextMove) ,
           ( move(LastMove,NextMove) ,
             eval(NextMove,Value) ) ,
           Children) ,           % Children sorted on Value
    merge(Children,Rest,NewAgenda) , % best-first
    tiles_a(NewAgenda,Goal,[LastMove|Visited0],Visited) .
```

## bLeftOfw



0	●●●○●●	9
1	●●●○●●	9
2	●●○●●●	8
4	●●○●●○	7
5	●●○●●○	7
6	●●○●○●	6
8	●○●●●●	4
9	●●○●●●	4
10	○●●●●●	3
12	○●●○●●	2
13	○●●○●●	1
15	○●○●●●	0

## outOfPlace



0	●●●○●●	12
1	●●●○●●	10
3	●●○●●●	9
4	○●●○●●	7
6	○●●○●●	7
8	○●●○●●	4
9	○●●○●●	4
11	○●○●●●	3
12	○●○●●●	2
14	○○●●●●	0



0	●●●○●●	18
1	●●●○●●	15
3	●●○●●●	13
4	●●○●●○	11
6	●○●●●●	8
7	○●●●●●	7
8	○●○●●●	7
9	○○●●●●	6
10	○●●○●●	6
12	○●●○●●	2
13	○●●○●●	2
15	○●○●●●	0

# Comparing heuristics

- A heuristic is (globally) ***optimistic*** or ***admissible*** if the estimated cost of **reaching a goal** is always less than the actual cost.

$$h(n) \leq h^*(n)$$

estimate of  
cost to reach  
goal from n


actual (unknown)  
cost to reach goal  
from n

- A heuristic is ***monotonic*** (locally optimistic) if the estimated cost of **reaching any node** is always less than the actual cost.

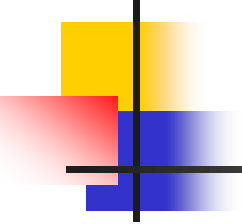
$$h(n_1) - h(n_2) \leq h^*(n_1) - h^*(n_2)$$

# Global and local optimism





# Non-monotonic heuristic

- 
- 
- Embora uma busca admissível (globally optimistic) leve a uma solução ótima, não é necessariamente verdade que cada nó seja alcançado ao longo do caminho ótimo.